Machine Learning

Université d'Haïti - Université Côte d'Azur
Richard Grin
Version 1.12 - 21/4/26

1

Plan de ce support

- Présentation du cours
- Généralités sur l'IA
- Machine learning
- Réseaux de neurones
- Transformeurs
- Références

2

Présentation du cours

- Ce cours
  Agents conversationnels en Java avec LangChain4j fait partie du parcours MBDS de la Faculté des Sciences de l'Université d'Etat d'Haïti
- Essentiellement **pratique** : comment tirer profit de l'IA dans les applications d'entreprise, en utilisant l'**API** de ces modèles
- Site Web du cours :
  http://richard.grin.free.fr/haiti/index.html

3

Examen

- Durée 2 heures, sans documents
- Vous choisissez la date, avec l'administration de la Faculté des Sciences
- Au moins 15 jours après la fin du cours, pour avoir le temps de finir les TPs car des questions pourront porter sur les TPs
- Le délégué me tient au courant assez rapidement de la date choisie
- Les bonus sont ajoutés à la note de l'examen pour avoir la note finale

4

Bonus

- Pour la réactivité : réponse aux emails en respectant les formats demandés, installation des logiciels, TPs terminés,…
- Pour les réponses aux questions pendant le cours
- Pour les questions intéressantes
- Retenez votre numéro dans la liste ; vous rappellerez ce numéro
  - si vous avez un bonus
  - dans vos emails
- Malus pour retards, manque de travail manifeste, triche, pas pour mauvaises réponses ou questions

5

Sujet email

- Tous les emails que m'enverrez doivent avoir un sujet qui respecte ce format :
  [HAITI-IA] sssssss - nn
  sans espaces à l'intérieur des crochets
- Par exemple
  [HAITI-IA] TP 0 terminé - 12
  pour un email qui informe que vous avez terminé le TP 0 et que vous avez le numéro 12 dans la liste des étudiants
  ou
  [HAITI-IA] Problème avec …. - 12
  si vous avez un problème quelconque et vous demandez de l'aide

6

TPs (1/2)

- **Indispensables** pour assimiler le cours
- Copier-coller du code sans essayer de le comprendre ne vous servira à rien, en particulier pour l'examen
- Vous pourrez terminer les TPs après mon départ et avant l'examen
- Bonus pour les TPs terminés avant la date limite

7

TPs (2/2)

- Travail personnel
  - Vous pouvez demander des explications à votre entourage ou à une IA, échanger des idées (**pas du code !**) avec d'autres étudiants
  - mais **vous devez écrire le code seul(e)**, en respectant ce qui est demandé dans les énoncés
  - **INTERDIT** de consulter les dépôts GitHub des autres étudiants

8

Rendre un TP

- Envoyer un email avec un sujet qui a le bon format : par exemple,
  [HAITI-IA] TP 2 terminé - 12
- L'email doit contenir l'URL du dépôt GitHub **public** qui contient votre code et les informations nécessaires pour accéder au dépôt
- Il doit aussi contenir directement (*pas dans un fichier joint*) les réponses aux questions posées ; ces réponses ne doivent apparaitre nulle part ailleurs (pas dans le README GitHub par exemple)

9

Indispensable pour bonus TPs

- Faire tous les **commits** (ou presque…)
- Répondre aux exercices ou questions posées
- Vous ne devez pas modifier le code fourni dans les TPs sauf si le TP vous le demande
- Si vous avez une raison importante de modifier le code, demandez l'autorisation à l'enseignant en expliquant les raisons

10

Erreurs basiques les plus communes pour les TPs

- Ne pas vérifier que les **pushs** ont été effectués
- Mauvaise version de Java (pom.xml)
- Mauvaise version de LangChain4j
- Plugins Maven pas à jour (aidez-vous de https://central.sonatype.com/ ou https://mvnrepository.com/)
- Pas de .gitignore pour Git
- Mauvais packages pour les classes (en particulier, votre nom doit apparaitre dans les noms des packages)

11

Demander de l'aide à l'enseignant ou sur le Web

- Lisez attentivement cette page : http://richard.grin.free.fr/haiti/tp/demandeaide.html
- En résumé :
  - Le minimum d'information à fournir :
    - environnement d'exécution (version de l'OS et des logiciels,…)
    - étapes qui ont conduit au problème
    - message d'erreur (et logs)
  - N'envoyez pas de copie d'écran, sauf exception

12

Abréviations des supports

- LM : *Language Model* ; modèle de langage utilisé, par exemple, par ChatGPT et Gemini
  LLM : *Large Language Model*

13

Supports du cours

- Support 1 : quelques concepts importants du machine learning (ML) et du deep learning (DL)
- Support 2 : embeddings et utilisation des LMs
- Support 3 : LangChain4j, framework standard de facto pour utiliser les LMs avec du code Java ; utilisé dans les TPs
- Support 4 : fine tuning et RAG qui permettent d'améliorer les réponses des LMs
- Support 5 : introduction à l'IA agentique et au protocole MCP

14

Intelligence artificielle

15

Définitions

Exemples de tâches qui demandent de l'intelligence ?

- IA : Système informatique capable d'effectuer des tâches typiquement associées à l'intelligence, telles que l'apprentissage, le raisonnement, la résolution de problèmes, la perception ou la prise de décision (Wikipedia)
- Le but est d'automatiser, de rendre plus rapides et plus efficaces des tâches qui demandent de l'intelligence
- Intelligence : capacité à comprendre, apprendre, s'adapter à des situations nouvelles, résoudre des problèmes dans un environnement donné

16

Quelques fonctions d'une IA (1/2)

- Prédiction : prévoir des résultats à partir de données ; par exemple, meilleur prix de vente d'un appartement compte tenu de ses caractéristiques
- Classification : classer des entités ; est-ce qu'un email est un spam ? diagnostic médical
- Détection : détecter des anomalies ; détecte une anomalie sur un objet fabriqué
- Conversation : dialoguer avec des humains
- Génération : créer du contenu ; écrire un récit, génèrer du code informatique ou des images

17

Quelques fonctions d'une IA (2/2)

- Optimisation / planification : trouver la meilleure solution sous contraintes ; GPS
- Raisonnement : déduire, expliquer ; démontrer un théorème en suivant des règles logiques
- Interaction avec un environnement : observer un environnement, décider, agir et s'adapter ; robot, véhicule autonome

18

Types d'IA

- IA « classique » (ou symbolique) : s'appuie sur des règles et des connaissances fournies par des experts humains ; produit typiquement des systèmes experts
- Apprentissage automatique (Machine learning, ML) : développe des **modèles** (logiciels) capables d'apprendre seuls à partir de données d'entrainement (pas de règles fournies par des humains)

Machine learning

Présentation

- 2 phases bien distinctes :
  - Durant la **phase d'apprentissage** on part d'un modèle *non entrainé* qu'on entraine à fournir des bonnes réponses à partir d'exemples (*dataset*)
  - Durant l'**inférence**, le modèle entrainé est utilisé pour prévoir des résultats, sur de nouvelles données
- L'apprentissage est souvent lourd et coûteux mais ne se fait qu'une seule fois ; nécessite des machines puissantes, avec GPU ou NPU (on peut en louer sur le cloud si utilisation peu fréquente)

Apprentissage

- Avec les exemples, le modèle va apprendre à reproduire le bon comportement : à trouver la bonne valeur à partir de données fournies en entrée
- Chaque exemple est composé
  - de valeurs $x_1, \ldots, x_n$ en entrée
  - d'une réponse y attendue pour ces valeurs en entrée
- Pour chaque exemple, le modèle est modifié pour que la valeur calculée soit la plus proche possible de la réponse attendue y
- Pour éviter le bruit (un exemple peut être aberrant), on regroupe souvent les exemples dans des *batchs*, groupe de quelques dizaines à quelques centaines d'exemples

Validation

- Lorsqu'on entraîne un modèle, il est important de ne pas utiliser tous les exemples pour la modification du modèle
- Il faut garder une partie des exemples pour valider le modèle, en cours et en fin d'apprentissage
- On teste ainsi, sur des exemples qu'il n'a jamais vus, la capacité du modèle à généraliser à des nouvelles situations

Diviser données apprentissage

- Pour la validation les exemples d'apprentissage sont divisés en 3 groupes :
  - Le plus nombreux pour modifier le modèle (par exemple 80 % des exemples)
  - Un groupe (validation) pour vérifier que tout se passe bien pendant l'apprentissage, en particulier éviter le surapprentissage (par exemple 10 %)
  - Le dernier groupe (test) pour tester l'efficacité du modèle final (par exemple 10 %)

Types de machine learning

- Dans le ML « classique », le *data scientist* choisit un type de modèle à utiliser (modèle linéaire, polynomial, arbre de décision, par exemple)
- L'apprentissage profond (deep learning, DL) a pour modèle un réseau de neurones
- Usage en entreprise : le ML classique est très utilisé pour les données structurées tandis que le deep learning a révolutionné l'IA pour le traitement des images, du texte et de l'audio

R. Grin ML 25

25

Data scientist

- Expert en science des données
- Capable d'extraire de la valeur à partir de données brutes
- En ML, ses tâches principales sont
  - choix et préparation des données d'entrainement
  - choix du type de modèle
  - évaluation du modèle

R. Grin ML 26

26

Exemples types de modèles

- Linéaire, polynomial - fonction linéaire, polynomiale, entre les variables d'entrée et de sortie (exemple : régression linéaire)
- Arbre de décision - utilise une structure d'arbre pour prendre des décisions ; des règles/questions déterminent le chemin dans l'arbre
- Clustering - regroupe des données en clusters (groupes) selon leur ressemblance ; exemple « k-means clustering » : on donne le nombre de groupes et l'algorithme définit les groupes

R. Grin ML 27

27

Modèle comme fonction

- Le modèle peut être vu comme une fonction (au sens mathématique) : $y = f(x_1, \ldots, x_n)$
- Il permet de trouver un résultat y à partir des données d'entrée x_i
  - Pour le type *régression*, y est numérique (valeur simple, vecteur,…)
  - Pour le type *catégoriel*, y est une catégorie (classification)
  - Pour le type *génératif*, y peut être du texte, une image, une vidéo, du son,…

R. Grin ML 28

28

IA générative (*GenAI*)

- Branche du DL qui génère des contenus nouveaux
- Les **LM**s (*Language Models*, modèles de langage) sont les logiciels d'IA générative les plus utilisés (ChatGPT, Gemini,…) ; ils génèrent des textes en langages naturels (français, anglais, …) pour des chats avec les utilisateurs, de la traduction de texte, …
- L'IA générative peut aussi générer du code, des images, de la musique, des vidéos, … ; on parlera alors de LMs **multimodaux** ou de **modèles de base**

R. Grin ML 29

29

Cas d'utilisation

- ML « classique », souvent avec des données structurées :
  - Prédiction de défauts de paiement (finance)
  - Classification de patients à risque (santé)
  - Décider si un email est un spam
  - Optimisation des stocks
- DL, souvent sur des données complexes, volumineuses, non structurées (textes, images, sons) :
  - Traitement du langage naturel (traduction, chatbot)
  - Vision par ordinateur (reconnaissance faciale, détection d'objets, diagnostic médical par imagerie)
  - Voitures autonomes, robots « intelligents »

R. Grin ML 30

30

ML classique, DL ou GenAI ?

Exemple 1 de modèle

- Modèle qui prédit si un client est susceptible d'acheter un certain produit
- Le modèle est entrainé avec de nombreux exemples **réels** de clients, avec leurs caractéristiques (âge, groupe social ou géographique, achats déjà effectués, …), en précisant si le client a acheté le produit
- Après l'entrainement, le modèle doit être capable de calculer la probabilité qu'un client achète le produit

R. Grin ML 31

31

ML classique, DL ou GenAI ?

Exemple 2 de modèle

- Modèle qui donne le prix d'un appartement à afficher, compte tenu de son emplacement, de sa superficie, de son étage, de son environnement, … pour qu'il trouve rapidement un acquéreur
- Pendant l'entrainement, on fournit au modèle les caractéristiques de très nombreux appartements qui ont été vendus, le prix de vente et le temps qu'il a fallu pour trouver un acquéreur

R. Grin ML 32

32

ML classique, DL ou GenAI ?

Exemple 3 de modèle

- Modèle qui indique si une photo contient des installations militaires
- Pendant l'entrainement, on fournit au modèle les caractéristiques de très nombreuses photos que des hommes ont classées « militaire » ou non

R. Grin ML 33

33

ML classique, DL ou GenAI ?

Exemple 4 de modèle

- Modèle qui génère une image à partir d'une description textuelle
- Pendant l'entrainement, on fournit au modèle des couples texte - image ; il existe des BDs (bases de données) de tels couples

R. Grin ML 34

34

Paramètres d'un modèle

- La plupart des types de modèle ont des paramètres définis à l'avance p1, p2, … qui déterminent le comportement du modèle
- Par exemple, si on choisit un modèle linéaire, le modèle est représenté par une fonction affine qui a 2 paramètres **a** et **b** : f(x) = **a**x + **b**
- Les valeurs de ces paramètres sont déterminées durant l'apprentissage pour minimiser les erreurs de prédiction sur les données d'apprentissage

R. Grin ML 35

35

Paramètres et hyperparamètres

- Les **paramètres** d'un modèle sont *internes* au modèle ; leurs valeurs sont *automatiquement* ajustées pendant l'apprentissage ; exemple : valeurs a et b d'un modèle linéaire
- Ne pas confondre avec les **hyperparamètres** qui sont des valeurs *choisies* pour paramétrer le modèle
  - pendant l'apprentissage du modèle : taille des pas pendant la descente de gradient, nombre des couches cachées des réseaux de neurones, …
  - pendant l'inférence : température, taille maximale de la réponse,…

R. Grin ML 36

36

Eléments pour apprentissage

- Nombreux types d'apprentissage mais ils utilisent tous plus ou moins les mêmes éléments :
  - **Exemples d'apprentissage** ; chaque exemple est composé des valeurs qu'on donne en entrée du modèle, et du résultat attendu pour ces entrées
  - **Modèle** ; logiciel qui apprend à partir de ces exemples
  - **Fonction de perte** ; mesure l'erreur faite par le modèle lorsqu'il est testé sur un batch d'apprentissage
  - **Algorithme d'optimisation** ; modifie le modèle pour réduire la fonction de perte
- Le but de l'apprentissage est de minimiser la fonction de perte en utilisant l'algorithme d'optimisation

37

Exemple régression linéaire (1/2)

- **Données d'apprentissage** : points qui correspondent aux données relevées
- **Modèle** : fonction affine f(x) = ax + b, représentée par une droite de régression

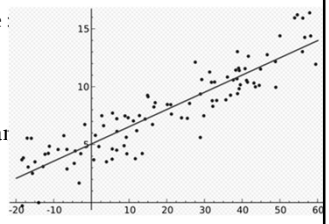

Dessin Wikipedia

A quoi correspondent les paramètres a et b pour la droite de régression ?

38

Exemple régression linéaire (2/2)

- **Fonction de perte** : « somme des distances » des points d'un batch d'apprentissage à la droite de régression
- **Algorithme d'optimisation** : modifie les valeurs de a et de b pour minimiser la somme, par exemple avec une descente de gradient

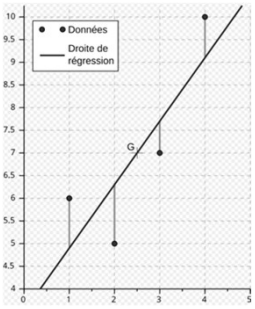

39

Etapes phase d'apprentissage

1. Préparation des données d'apprentissage
2. Fixer des hyperparamètres d'apprentissage (par exemple, profondeur d'un arbre de décision, nombre de couches de neurones ou taux d'apprentissage)
3. Utiliser les exemples d'apprentissage pour améliorer les paramètres internes du modèle
4. Validation du modèle sur les exemples de validation ; si la validation échoue, on peut être amené à changer les hyperparamètres et en ce cas il faut recommencer l'étape 3

40

Préparer données apprentissage

- Très important
- Les données en entrée sont souvent préparées pour supprimer le bruit et les données erronées ; par exemple suppression de balise HTML, correction fautes d'orthographe, espaces superflus, …
- Eliminer les biais ; par exemple sur catégories de personnes (sexe, groupe ethnique, …)
- Gestion des données sensibles (enlever les mots de passe, les clés secrètes, anonymiser, …)
- Ajout éventuel de contexte

41

Apprentissage (1/2)

- But : ajuster les paramètres pour le modèle
- On commence par donner des valeurs (aléatoires, si pas d'informations spéciales) aux paramètres du modèle
- Pour chaque exemple (ou groupe d'exemples, *batch*) d'apprentissage
  - La fonction de perte dépend des paramètres du modèle (calcul de la valeur de sortie du modèle) et de l'exemple (valeur en entrée et attendue en sortie)
  - L'algorithme d'optimisation modifie les paramètres du modèle pour minimiser la perte

42

Apprentissage (2/2)

- Avec les nouveaux paramètres mis à jour, on refait le même processus avec l'exemple d'apprentissage suivant, et ainsi de suite, jusqu'au dernier exemple du groupe d'apprentissage (fin d'une époque)
- On peut alors s'arrêter ou commencer une nouvelle époque avec un groupe d'exemples différents, ou identiques mais pas dans le même ordre
- L'apprentissage s'arrête quand la perte augmente sur les données de validation (souvent testées à chaque fin d'époque), pour éviter le surapprentissage
- Un test final sur de nouveaux exemples permet alors de valider ou non le modèle

43

Surapprentissage

- Il faut savoir s'arrêter à temps dans l'apprentissage
- Si on s'arrête trop tard, on va faire du surapprentissage (overfitting) : le modèle obtenu sera surentrainé sur les données d'entrainement, y compris les données aberrantes (le « bruit »), mais ne donnera pas des bons résultats avec des données de validation

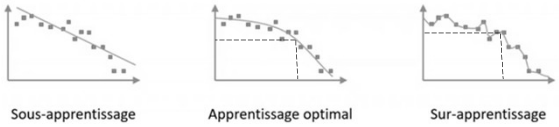

Source images : https://www.youtube.com/watch?v=kwgR-Qu56MA

44

Types d'apprentissages

- Supervisé (supervised learning, SL)
- Non supervisé (unsupervised learning, UL)
- Auto-supervisé (self-supervised learning, SSL)
- Par renforcement (reinforcement learning, RL)

45

Apprentissage supervisé

- Exemple d'apprentissage : une entrée (texte, image, caractéristiques, …), et une étiquette ou variable cible en sortie **fournie par des humains**
- Par exemple
  - Photos de chiens et de chats étiquetées « chien » ou « chat » par des humains
  - Caractéristiques d'appartement (étage, emplacement, superficie,…) récemment vendus avec leur prix de vente et la durée entre la mise en vente et l'achat

46

Apprentissage non supervisé

- Le modèle doit trouver des patterns ou des relations entre des données, sans recevoir d'aide
- Les données d'entrainement ne sont pas étiquetées
- L'objectif peut être
  - d'extraire des classes d'individus présentant des caractéristiques communes (clustering) ; les définitions des classes ne sont pas données a priori
  - de trouver des associations entre les données ; par exemple indiquer que les clients qui achètent du pain achètent aussi souvent du beurre
- Moins performant que l'apprentissage supervisé mais intéressant si l'étiquetage est complexe ou coûteux

47

Apprentissage auto-supervisé

- Intermédiaire entre apprentissage supervisé et non supervisé
- Le modèle apprend à partir d'échantillons de données non annotées ; des « étiquettes » sont générées automatiquement à partir des données d'entrainement
- Par exemple, l'entrainement d'une IA textuelle générative peut se faire en tronquant des phrases récupérées dans un livre ou sur Internet ; l'IA doit retrouver la partie cachée qui est la variable cible

48

Apprentissage par renforcement

- Le logiciel apprend en interagissant avec un environnement
- Il reçoit un feedback (retour d'information) en recevant des récompenses ou des pénalités en fonction des actions qu'il entreprend dans l'environnement
- Souvent utilisé quand les données d'entrainement sont rares ; l'IA apprend par essais et erreurs

R. Grin ML 49

49

Apprentissage par renforcement avec rétroaction humaine

- RLHF : Reinforcement Learning from Human Feedback
- Utilisé pour affiner les modèles, en particulier les LLMs
- Exemples d'interactions :
  - Des testeurs humains donnent leur avis sur les réponses des modèles
  - Plusieurs réponses peuvent être proposées aux testeurs par le modèle, en demandant la meilleure réponse
  - Demander aux testeurs de sélectionner avec la souris des objets dans une image

R. Grin ML 50

50

Distillation des connaissances

- Apparue avec les LLMs
- Technique d'apprentissage automatique qui transfère les connaissances d'un grand modèle, le modèle « enseignant » à un modèle « élève » plus petit qui apprend à imiter les prédictions du modèle enseignant, comme avec un apprentissage supervisé
- On peut ainsi avoir un modèle plus petit, plus rapide, moins gourmand en ressources tout en gardant des connaissances proches du modèle enseignant
- Il peut y avoir des inconvénients : par exemple perte de précision par rapport à l'enseignant, reproduction des erreurs de l'enseignant

R. Grin ML 51

51

Réseaux de neurones

R. Grin ML 52

52

Cerveau humain

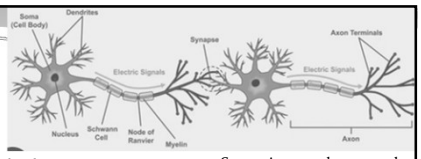

Source image : shutterstock

- 86 à 100 milliards de neurones
- Par neurone, environ 2000 dendrites (points d'entrée) ; le plus souvent un seul axone (point de sortie) mais avec plusieurs ramifications
- Chaque synapse (connexion axone-dendrite) peut être utilisée plusieurs centaines de fois par seconde
- Très efficace en énergie : consommation de 20 watts (quelques **k**watts pour une IA)
- Apprendre c'est créer, supprimer des synapses, modifier leur sensibilité

R. Grin ML 53

53

1ère simulation d'un neurone : le perceptron

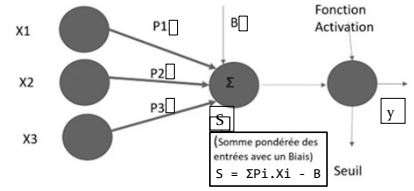

Frank Rosenblatt, 1957

- Un perceptron a des paramètres `Pi` (**poids**) et `B` (seuil ou **biais**)
- Il reçoit n valeurs `Xi` en entrée et calcule la somme pondérée `S` de ces valeurs ; la fonction d'activation retourne la valeur finale `1` si `S - B ≥ 0`, et `0` sinon

R. Grin ML 54

54

Neurones artificiels

- La fonction d'activation du perceptron est trop simple et elle n'est pas continue, donc pas dérivable
- Les neurones artificiels « modernes » sont des évolutions du perceptron avec, en particulier, des fonctions d'activation dérivables qui vont permettre d'utiliser la descente de gradient

55

Fonction d'activation

- Perceptron : la sortie du perceptron est y = H(ΣPi1.Xi - B), avec H(z) = 1 si z ≥ 0, ou 0 sinon
- Neurone artificiel : on remplace H par une fonction dérivable
- Par exemple, avec la fonction d'activation sigmoïde (d'autres choix sont possibles), la sortie du neurone est donnée par (w_i sont les poids, b est le biais)

$$y = \frac{1}{1 + e^{-(\sum w_i x_i + b)}}$$

56

Types de fonctions d'activation

1. **Sigmoïde :** $\sigma(x) = 1 / (1+e^{-x})$ - Produit des sorties dans la plage de 0 à 1 ; utilisée dans les couches de sortie pour les problèmes de classification binaire
2. **Tangente hyperbolique (tanh) :** $\tanh(x) = (e^{-x} - e^{-x}) / (e^{-x} + e^{-x})$ - Produit des sorties dans la plage de -1 à 1, permet de gérer les valeurs négatives
3. **ReLU (Rectified Linear Unit) :** ReLU(x) = max(0, x) - Renvoie simplement zéro pour les valeurs négatives et laisse les valeurs positives inchangées. Une des fonctions d'activation les plus populaires pour les couches cachées
4. **Leaky ReLU :** Leaky ReLU(x) = max(αx, x) - Variation de ReLU qui permet un faible taux de fuite (α est une petite valeur constante pour les entrées négatives) pour éviter certains problèmes liés à ReLU
5. **Softmax :** Souvent utilisée dans la couche de sortie pour les problèmes de classification multi-classes - convertit un vecteur de nombres réels en une distribution de probabilité

57

Réseaux de neurones artificiels

- Les neurones artificiels sont regroupés en réseaux
- Ces réseaux sont structurés en couches de neurones
- Les valeurs calculées par les neurones d'une couche sont envoyées en entrée des neurones de la couche suivante

58

Couches réseau de neurones

- La couche d'entrée reçoit des valeurs de l'extérieur du réseau et les transmet aux neurones de la couche suivante
- La couche de sortie fournit à l'extérieur un résultat calculé par le réseau de neurones
- Entre ces 2 couches, les couches intermédiaires, dites cachées, participent au résultat calculé par le réseau
- Souvent les neurones d'une couche sont connectés à tous les neurones de la couche précédente et de la couche suivante

59

Exemple

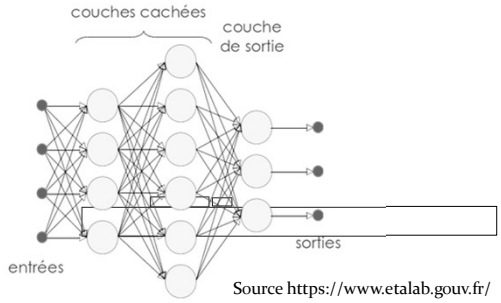

Source https://www.etalab.gouv.fr/

60

Paramètres du réseau

- Poids p_{ij} de toutes les liaisons entre neurones et biais b_i des neurones
- Déterminent le comportement du réseau
- Calculés lors de la phase d'apprentissage en utilisant les exemples d'apprentissage

61

Améliorer les résultats

- Rappel : La qualité des résultats d'un modèle sur un exemple d'apprentissage est donnée par la fonction de perte

  Comment est calculée la fonction de perte ?

  De quoi dépend la fonction de perte ?
- L'algorithme d'apprentissage va donc essayer de trouver des paramètres du réseau qui vont minimiser la fonction de perte

62

Descente de gradient

- Méthode mathématique pour trouver progressivement les valeurs des variables qui minimisent une fonction
- A chaque pas, on part des valeurs actuelles des variables d'une fonction et on modifie légèrement ces valeurs pour minimiser la valeur de la fonction :
  1. Le gradient de la fonction de perte est calculé au point qui correspond aux valeurs actuelles des variables
  2. Les nouvelles valeurs des variables sont calculées par un déplacement d'un certain pas dans la direction opposée au gradient (le gradient d'une fonction indique la direction de la plus forte augmentation de la fonction)

63

Rétropropagation

- Le calcul du gradient se fait par rétropropagation
- Pour chaque batch, ce calcul se fait *en remontant de la couche de sortie vers la couche d'entrée* du réseau de neurones :
  - calcul de la dérivée partielle par rapport aux paramètres de la dernière couche
  - puis on passe à la couche précédente
  - et ainsi de suite, jusqu'à arriver à la première couche

64

Rappels mathématiques

- Le gradient d'une fonction f à plusieurs variables est le vecteur de ses dérivées partielles :

  $$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n}\right)$$

  La valeur du gradient en un point indique la direction où la fonction augmente le plus vite autour de ce point (la « direction de la plus grande pente »)
- Soit un point $(x_1, \ldots, x_n)$; si on veut un point proche pour lequel la valeur de la fonction sera la plus faible, on va dans la direction opposée à la direction du gradient en ce point

65

Etapes calcul des paramètres

- 2 étapes pour chaque exemple (ou groupe d'exemples) d'apprentissage :
  1. Calcul des gradients de la fonction de perte par rapport aux paramètres, par rétropropagation (*back propagation*)
  2. Ajustement des paramètres par descente de gradient, pour minimiser la fonction de perte qui calcule la distance entre
     - la valeur calculée par le réseau
     - la valeur attendue pour l'exemple d'apprentissage

66

Détails de la rétropropagation

- Fonction de perte L ; elle dépend des matrices W_i des paramètres de la couche numéro i vers la couche numéro i + 1 (on suppose n couches cachées)
  - $\partial L/\partial W_{n+1}$ est d'abord calculé (W_{n+1} contient les paramètres de la dernière couche cachée vers la couche de sortie)
  - puis $\partial L/\partial W_n$ est calculé en utilisant le résultat du calcul précédent
  - et ainsi de suite pour arriver à la fin au calcul de $\partial L/\partial W_1$ (W_1 représente les paramètres de la couche d'entrée vers la 1ère couche cachée)

Algorithme de descente de gradient

- Algorithme d'optimisation qui cherche les valeurs (x_1, …, x_n) pour lesquelles $f(x_1, \ldots, x_n)$ est minimal
- On part d'un point et on se déplace d'un certain pas en allant dans le sens opposé à la direction du gradient en ce point (« on suit la plus grande pente descendante »)
- On réitère l'opération en partant du nouveau point, et ainsi de suite
- Si la fonction a les bonnes propriétés, on espère arriver ainsi à un point proche du point où la fonction est minimale

Descente de gradient appliquée à la fonction de perte

- La valeur de la fonction de perte pour un exemple d'apprentissage dépend des paramètres du modèle (les valeurs de l'exemple d'apprentissage sont fixes) ; les paramètres du réseau de neurones jouent le rôle des x_i
- Pour chaque batch d'apprentissage, on modifie les paramètres du modèle en appliquant la descente de gradient (on suit la plus grande pente descendante)
- A la fin de l'apprentissage les paramètres du modèle minimisent la fonction de perte (valeurs calculées par le modèle sont proches des valeurs attendues des exemples)

Visualiser la descente de gradient

- Représenter la fonction de perte comme une hypersurface (« surface qui a une dimension de moins que l'espace auquel elle appartient ») aide à visualiser le principe de la descente de gradient

Fonction de perte représentée par une hypersurface

- La fonction de perte L dépend des n paramètres du modèle et elle fournit une seule valeur (l'erreur, la distance entre la valeur calculée et la valeur prévue)
- Elle peut donc être représentée par une hypersurface de dimension n dans un espace de dimension n + 1
- Par exemple,
  - si n = 1, une hypersurface est une courbe dans le plan ; fonction de perte de type `y = L(p1)`
  - si n = 2, une hypersurface est une surface dans l'espace ; fonction de perte de type `y = L(p1, p2)`

En dimension 2 (n = 1 paramètre)

- L'algorithme de la descente de gradient revient à se déplacer dans le plan (donc à modifier l'unique paramètre) *en prenant la direction de la plus grande pente descendante* pour minimiser la valeur de la fonction de perte

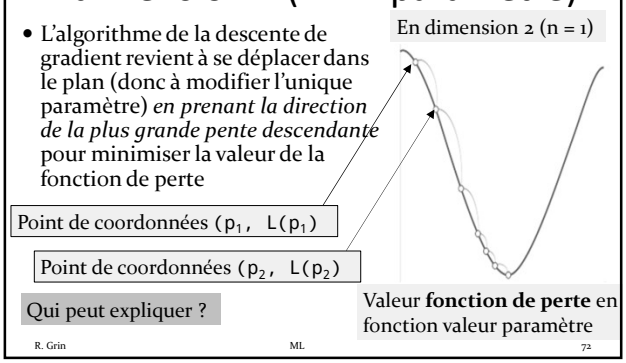

En dimension 3 (n = 2 paramètres)

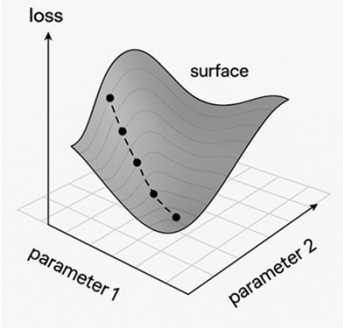

Remarque : ne pas oublier que dans le cas d'un réseau de neurones, n est bien souvent au moins égal à plusieurs milliards…

Image générée par IA

73

Taux d'apprentissage

- La longueur du déplacement en direction de la plus grande pente descendante est un hyperparamètre de l'algorithme d'apprentissage, qui s'appelle le *learning rate* (taux d'apprentissage)
- Si le pas est trop petit, l'algorithme se rapproche trop lentement du minimum ; s'il est trop grand, on risque de ne pas se rapprocher du minimum (oscillation autour du minimum)

74

Théorème d'approximation universelle

- Rappel : un réseau de neurones peut être considéré comme une fonction $f(x_1, \ldots, x_n)$
- Théorème : un réseau de neurones peut approcher une fonction quelconque d'aussi près que l'on veut
- « Un réseau de neurones à une seule couche cachée, utilisant une fonction d'activation non linéaire appropriée (comme sigmoïde, tanh, ReLU…), peut approximer n'importe quelle fonction continue sur un compact de R^n, aussi précisément que l'on veut, à condition d'avoir suffisamment de neurones dans cette couche » ; https://fr.wikipedia.org/wiki/Th%C3%A9or%C3%A8me_d%27approximation_universelle

75

Fonction approchée par un LM

- L'entrainement du LM va permettre de trouver les paramètres pour approcher une fonction qui
  - prend un texte en entrée
  - renvoie en sortie, pour chaque mot du vocabulaire, la probabilité que ce mot convienne pour compléter le texte (selon textes donnés lors de l'apprentissage du LM)

76

Application à la génération de texte

- Le but d'un LM étant la génération de texte, la fonction approchée va être utilisée pour cette **fonction de base** :
  - prend un texte en entrée
  - renvoie en sortie un des mots les plus probables pour compléter le texte
- Pendant l'inférence, le LM va utiliser cette fonction pour générer du texte **mot par mot** (plutôt token par token, comme on va le voir)
- Par exemple, pour répondre à une question ou pour générer la traduction d'un texte

77

Traitement des textes

- On a vu que les réseaux de neurones font des calculs sur des données **numériques** en entrée pour calculer des données en sortie
- Comment les textes sont-ils transformés en nombres pour être manipulés par les réseaux de neurones ?
- Les textes sont transformés en nombres en 2 étapes :
  1. Ils sont découpés en **tokens**
  2. Chaque token est ensuite transformé en un vecteur de nombres réels appelé **embedding**

78

Token

- Unité minimale de texte traitée par un réseau de neurones
- Un token peut être un mot, mais aussi une partie de mot ou un signe de ponctuation
- Il existe aussi des tokens spéciaux ; par exemple les tokens de début et de fin de génération
- La décomposition d'un mot en tokens dépend du *tokenizer* utilisé, logiciel qui effectue le découpage

R. Grin ML 79

79

Exemples découpage en tokens

- Tests avec plusieurs tokenizers à l'adresse https://huggingface.co/spaces/Xenova/the-tokenizer-playground ; on voit que des tokenizers différents donnent souvent des découpages différents
- « smartphone » est décomposé en 2 tokens « smart » et « phone » par des tokenizers mais peut aussi ne pas être découpé
- dermatologue peut être découpé de multiples façons : der mat ologue, ou bien d, erm, at, olog, ue (!) par exemple

R. Grin ML 80

80

Exemple génération de texte pour répondre à une question

- Question « Quel est le plus grand océan du monde ? »

1. Le texte est découpé en tokens : « Quel », « est », …
2. Le modèle génère le 1er token de la réponse pour compléter la question : « **L** »
3. Puis il génère le token « ' » qui complète « Quel est le plus grand océan du monde ? **L** »
4. Et ainsi de suite, pour finalement générer « L'océan Pacifique. »
5. Pour finir, le token généré suivant est le token spécial qui indique que la génération est terminée

R. Grin ML 81

81

Vocabulaire

- C'est l'ensemble des tokens utilisés dans une langue (ou dans plusieurs langues)

R. Grin ML 82

82

Embedding

- Chaque token est représenté par un vecteur de nombres réels, appelé embedding
- Le passage aux embeddings va permettre
  - d'effectuer des calculs mathématiques sur les données manipulées
  - mais aussi d'ajouter du sens au texte ; des tokens ayant un sens proche sont traduits par des embeddings proches (voir support de cours suivant)

R. Grin ML 83

83

ONNX

- Open Neural Network Exchange
- Format ouvert et open source pour représenter les modèles
- Permet d'échanger des modèles entre différents frameworks et environnements d'exécution
- Facilite l'interopérabilité entre les outils de DL comme PyTorch, TensorFlow, etc.

R. Grin ML 84

84

Types principaux de réseaux de neurones

- De convolution (CNN ; Convolutional Neural Network)
- Récurrent (RNN ; Recurrent Neural Network)
- Transformeur

85

CNN

- Type de réseau de neurones spécialement conçu pour traiter les **images**

86

CNN - Filtres

- Analyse l'image par petites zones pour identifier des caractéristiques importantes (contours, texture, …) en effectuant une opération mathématique appelée convolution
- Un CNN passe l'image d'entrée à travers plusieurs filtres pour détecter des caractéristiques de plus en plus complexes : d'abord des contours et textures de base, ensuite des formes géométriques, des objets, des visages
- Ces caractéristiques sont enregistrées dans des cartes de caractéristiques

87

CNN - Pooling

- Permet de réduire la taille des cartes de caractéristiques en conservant les informations les plus importantes
- Consiste à diviser l'image en plusieurs petites zones (par exemple 2 x 2 pixels) et à remplacer la zone par un seul point avec une seule valeur pour chacune des caractéristiques
- La valeur du point peut être le max, la moyenne, ou être obtenue par une autre opération à partir des valeurs des pixels de la zone

88

CNN - Réseau de neurones

- Finalement, les informations extraites des filtres et du pooling sont envoyées en entrée d'un réseau de neurones pour donner une réponse ; par exemple pour savoir si une image représente un chien, un chat ou un oiseau

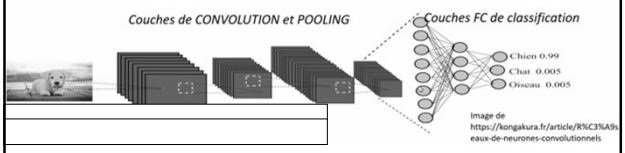

Image de https://kongakura.fr/article/R%C3%A9seaux-de-neurones-convolutionnels

89

Réseaux de neurones récurrents

- Les RNNs ont été introduits pour traiter les données ordonnées en séquences : texte, image, son,..
- Le traitement utilise une chaîne de réseaux de neurones (le même réseau est utilisé dans toute la chaîne) ; à chaque étape la sortie d'un réseau de la chaîne est donnée en entrée au réseau suivant
- Exemple : 1er mot d'une phrase est donné en entrée au réseau puis on donne en entrée au 2ème réseau la sortie du 1er réseau et le 2ème mot de la phrase, etc.

90

Problèmes RNNs

- Traitement séquentiel des tokens, donc apprentissage long et moins performant pendant leur utilisation
- Difficulté à capturer les relations complexes entre les éléments de la séquence ou les relations entre éléments éloignés
- Biais temporel : les premiers éléments d'une séquence sont traités différemment des derniers
- Les transformeurs réduisent fortement ces problèmes

91

Transformeurs

92

Présentation

- Architecture pour traiter des séquences de données ; utilise des réseaux de neurones
- Peut prendre en charge plusieurs types de données : texte, image, vidéo, série temporelle,… ; dans la suite on se limitera aux textes

93

Couche d'attention

- Un transformeur est composé de plusieurs modules ; chacun des modules modifie les embeddings qu'il reçoit en entrée
- Le module essentiel, appelé la **couche d'attention**, prend en compte les relations entre les éléments de la séquence, quelle que soit leur distance dans la séquence
- Grâce essentiellement à cette couche d'attention, les transformeurs ont révolutionné l'IA générative en permettant de créer des modèles très puissants de génération de texte

94

Motivation

- La génération du mot suivant par un LM implique une bonne compréhension du texte à compléter
- Pour cela, il ne suffit pas de comprendre chaque mot isolément
- Il faut tenir compte de la syntaxe de la langue, du contexte de chaque mot et des relations entre les mots
- Les transformeurs peuvent extraire ces informations d'un texte, et les insérer dans les embeddings

95

Exemple

- « Pierre a oublié ses lunettes sur le banc sur lequel il s'était assis. »
- Un transformeur, plus précisément la couche d'attention, va capturer la relation entre « banc » et « assis », bien qu'ils soient séparés ; il a appris que ces mots sont souvent liés, parce qu'ils apparaissent souvent ensemble dans les phrases sur lesquelles on l'a entrainé
- Il va aussi associer « Pierre » et « il »

96

Structure d'un transformeur

- Essentiellement 2 parties : décodeur et encodeur (en fait, une pile d'encodeurs et une pile de décodeurs)
- Un transformeur peut n'utiliser qu'une de ces parties ; par exemple, GPT-4 n'utilise qu'une pile de décodeurs
- L'**encodeur** enrichit une séquence d'embeddings en entrée, en produisant une représentation contextuelle de chaque élément de la séquence
- Le **décodeur** génère une sortie, élément par élément

Représentation contextuelle ?

97

Exemple : traduction de texte

- Traduire du texte « mot à mot » (plus exactement token par token) fournit une mauvaise traduction
- Il faut 2 étapes pour une traduction acceptable :
  1. Encodeur transforme $x = (x_1, \ldots, x_n)$ en $z = (z_1, \ldots, z_n)$; les z_i sont enrichis par le contexte (relations avec les autres embeddings)
  2. Décodeur génère $y = (y_1, \ldots, y_m)$ à partir de z (le plus souvent $n \neq m$) ; processus autorégressif : y_p est généré en utilisant les y_i déjà générés ($i < p$), jusqu'à atteindre le token de fin

Exemple simple de traduction français-anglais avec $n \neq m$?

98

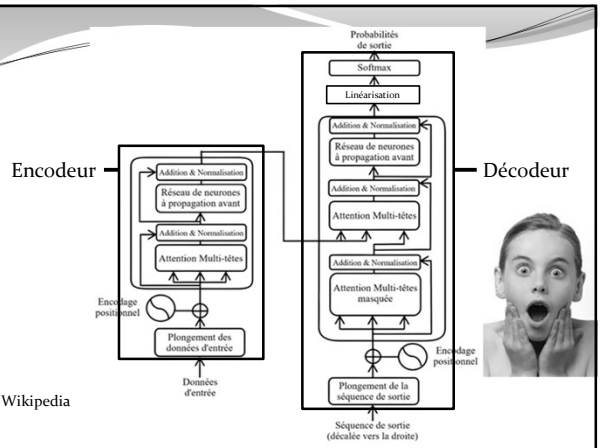

Wikipedia

99

Types de traitement

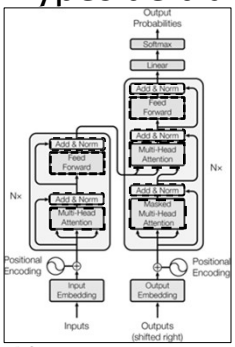

- Couche d'attention
- Réseau de neurones (Feed Forward)
- Addition et normalisation
- Chacune de ces étapes modifie les embeddings

100

- La suite de ce support détaille les processus qui s'exécutent dans les transformeurs ; elle est destinée à ceux qui veulent en savoir plus, mais elle ne fait pas partie du programme à connaitre pour l'examen

101

Utilité des éléments (1/2)

- **Couche d'attention** : capture dans les embeddings les **relations entre les tokens**, même s'ils sont éloignés dans la séquence
- **Réseau de neurones** (Feed-forward) : l'étape de l'attention est essentiellement linéaire ; le réseau de neurones utilise sa non-linéarité pour apprendre des informations plus complexes et enrichir **chaque embedding indépendamment** pour mieux représenter son rôle dans la phrase

102

Utilité des éléments (2/2)

- L'addition et la normalisation se font après chaque traitement
  - **Addition** : les données en entrée sont ajoutées aux données en sortie, ce qui évite qu'elles soient noyées dans les nouvelles données
  - **Normalisation** : évite des problèmes techniques durant l'apprentissage en réduisant les différences de grandeur entre les valeurs calculées ; évite en particulier « l'explosion » et « l'extinction » des gradients

R. Grin ML 103

103

Encodeur

- Transforme la séquence d'entrée (par exemple un texte qui représente une question, ou un texte à traduire) en une séquence d'embeddings
- Les embeddings sont traités en parallèle
- Utilise un mécanisme d'**attention** qui permet de s'intéresser plus particulièrement à certaines parties de la séquence d'entrée et de détecter les relations entre ces parties, même si elles sont éloignées dans la séquence
- Le résultat est une représentation enrichie de la séquence d'entrée (même nombre d'embeddings)

R. Grin ML 104

104

Décodeur

- De base, prend une séquence de tokens et sort le token suivant (itérativement une séquence de tokens)
- Si traitement préalable par encodeur, utilise la représentation enrichie de la séquence d'entrée fournie par l'encodeur pour générer une séquence de sortie
- Génère la séquence de sortie token par token, en se basant sur les informations fournies par l'encodeur, et sur les tokens qu'il a déjà générés
- Pour chaque itération, les probabilités de tous les tokens du vocabulaire sont calculées et le transformeur en choisit un (le choix dépend des hyperparamètres)

R. Grin ML 105

105

Encodeur ou/et décodeur

- Peuvent être utilisés indépendamment
- Modèles uniquement encodeurs : pour tâches qui nécessitent une compréhension de l'entrée, comme classification de phrases, analyse de sentiments, recherche de mots masqués
- Modèles uniquement décodeurs : pour tâches génératives telles que la génération de texte
- Modèles encodeurs-décodeurs : pour tâches génératives qui nécessitent une entrée, telles que la traduction ou le résumé de texte

R. Grin ML 106

106

Travail préparatoire pour encodeur et décodeur

1. Séquence d'entrée est découpée en tokens
2. Chaque token est transformé en embedding, vecteur numérique de grande dimension
3. Tous les embeddings sont traités en parallèle ; l'encodage positionnel ajoute aux embeddings des informations sur la position des tokens

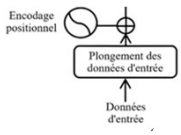

R. Grin ML

107

Encodage positionnel

- Un grand avantage pour l'efficacité des transformeurs par rapport aux réseaux récurrents est qu'ils peuvent traiter en parallèle tous les embeddings en entrée
- Pour ne pas perdre la position de chaque token dans la séquence, cette information est codée dans un vecteur de même dimension que l'embedding, et ajoutée à l'embedding

R. Grin ML 108

108

Addition et normalisation

- Chaque étape importante des encodeurs et décodeurs est suivie d'une étape d'addition et de normalisation
- **Addition** : ajoute aux embeddings des informations fournies par l'étape précédente (par exemple la couche d'attention) pour que cette information ne soit pas « oubliée » car déformée par la dernière étape
- **Normalisation** : il peut y avoir des variations importantes d'amplitude dans les valeurs fournies par les différentes étapes, ce qui peut fausser le travail effectué dans les étapes suivantes ; la normalisation contrôle ces variations

R. Grin ML 109

109

Partie 1 : encodeur

Enrichit la séquence d'entrée

R. Grin ML 110

110

Multi-head (ou self-) attention

- Etape très importante qui permet à l'encodeur de se concentrer sur les embeddings importants de la séquence d'entrée et de capturer à quel point chaque embedding est relié à chaque autre embedding
- A la sortie les embeddings sont enrichis avec l'attention

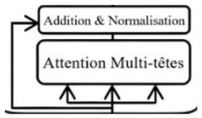

R. Grin ML 111

111

Utilité de l'étape d'attention

- Sens des mots :
  - « Je n'ai pas pu aller à mon cours de batterie car la batterie de ma voiture est tombée en panne »
  - La seule façon de distinguer les 2 sens du mot « batterie » est d'analyser le contexte qui l'entoure ; l'attention le fait (relation de « batterie » avec « cours » ou bien avec « voiture »)
- Relation entre les mots :
  - « Jean a montré à Paul où il devait signer. »
  - L'attention va permettre d'associer « il » à Paul

R. Grin ML 112

112

Pourquoi « plusieurs têtes » ?

- On peut prêter attention à plusieurs choses dans une phrase
- De plus, une phrase peut être ambiguë : « Robert a vu Bernard avec le télescope » peut avoir 2 sens
- Une tête d'attention va associer « Robert », « a vu » et « Bernard », alors qu'une autre tête va associer « Bernard » et « avec le télescope »
- Les différentes têtes peuvent identifier différentes relations entre les mots ; les embeddings capturent ces différentes interprétations qui pourront être résolues par la suite avec le contexte

R. Grin ML 113

113

Réseau de neurones à propagation avant

7. Feed-forward layer : les embeddings contextuels (enrichis) sont transmis à un réseau de neurones
8. Le réseau de neurones permet d'extraire les caractéristiques de plus haut niveau, grâce à ses capacités linguistiques et à ses connaissances générales

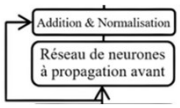

R. Grin ML 114

114

Partie 2 : décodeur

Génère la séquence de sortie, token par token, à partir de la séquence d'entrée enrichie par le travail de l'encodeur

115

Globalement

- Au début du traitement, la séquence de sortie du décodeur est vide (en fait, elle contient un token spécial de début de séquence) ; elle se remplit au fur et à mesure du traitement
- Celui-ci génère alors le 1er token qui est ajouté à la séquence de sortie du décodeur et on revient au début du traitement du décodeur
- Le décodeur génère ensuite le 2ème token, ajouté lui aussi à la séquence de sortie, et ainsi de suite, jusqu'à ce que le décodeur génère un token d'arrêt

116

Masked multi-head attention

- « Self-attention »
- Comme pour l'encodeur, ajoute des informations d'attention sur la séquence de sortie déjà générée pour comprendre les relations entre ses tokens
- « Masked » car, pendant l'entrainement, on masque les tokens qui suivent le dernier token généré pour simuler ce qui va se passer pendant l'inférence : à ce stade de la génération, on ne connait pas les tokens à droite du dernier mot généré
- Par souci de consistance, cette étape est conservée pendant l'inférence

117

Multi-head attention

- « Cross-attention » ; différente de « self-attention » car utilise la séquence de sortie déjà générée **et** la séquence d'entrée enrichie par l'encodeur (étape éliminée si pas d'encodeur)
- Enrichit les embeddings de la sortie du décodeur en intégrant ceux de l'entrée ; particulièrement utile pour les tâches de traduction

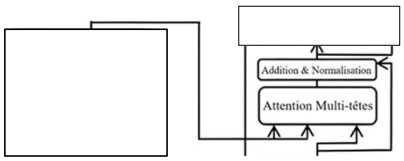

Encodeur Décodeur

118

Réseau de neurones

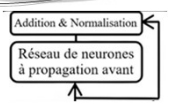

- En entrée, les embeddings enrichis par la couche d'attention
- La couche de sortie a autant de neurones que la dimension des embeddings utilisés
- Les valeurs de tous ces neurones de la couche de sortie décrivent à quoi va ressembler le prochain token (représentation riche et contextuelle de ce token)
- Les étapes suivantes vont permettre de calculer la distribution de probabilité des éléments du vocabulaire

119

Linéarisation

- Prend en entrée l'embedding h, issu de la sortie du dernier bloc feed forward ; h est une représentation riche de l'embedding du token qui est attendu comme prochain token
- Permet de calculer le score (*logit*) de chaque élément du vocabulaire pour être le prochain token, en utilisant h et une matrice (apprise par rétropropagation), dite matrice de projection,

120

Softmax, probabilités de sortie

- Softmax : Fonction qui génère des probabilités à partir des logits; indique les chances que le modèle choisisse chaque token comme prochain token dans la séquence
- Prédiction prochain token peut être faite de plusieurs manières :
  - Choisir le token le plus probable
  - Choisir le token parmi les plus probables (le choix aléatoire se fait en tenant compte des probabilités)

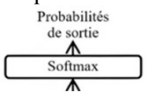

121

Références

122

IA pour les décideurs

- Présentation de l'IA pour les décideurs (2021 ; UNESCO): https://unesdoc.unesco.org/ark:/48223/pf0000380006

123

MOOCs gratuits

- L'Intelligence Artificielle… avec intelligence ! : https://www.fun-mooc.fr/fr/cours/lintelligence-artificielle-avec-intelligence/
- Intelligence artificielle pour et par les enseignants : https://www.fun-mooc.fr/fr/cours/intelligence-artificielle-pour-et-par-les-enseignants-ai4t/

124

- Lexique IA : https://www.editions-eni.fr/lexique-intelligence-artificielle-chatgpt
- Teachable machine de Google pour créer des modèles de ML rapidement et simplement, avec des images ou de l'audio, ou des poses (par exemple lever le bras) : https://teachablemachine.withgoogle.com/

125

- Lexique IA : https://www.editions-eni.fr/lexique-intelligence-artificielle-chatgpt
- Teachable machine de Google pour créer des modèles de ML rapidement et simplement, avec des images ou de l'audio, ou des poses (par exemple lever le bras) : https://teachablemachine.withgoogle.com/

126

Vidéos sur IA

- Vidéo de 2 h 45 très intéressante de Yann Lecun sur l'IA en général et les limites des LLMs, en particulier des modèles non open source : https://www.youtube.com/watch?v=5t1vTLU7s40
- Dangers potentiels de l'IA ; interview de Yoshua Bengio : https://www.youtube.com/watch?v=6Zm-z032YBg

127

Vidéos pour machine learning

- https://www.youtube.com/channel/UCtYLUTtgS3k1Fg4y5tAhLbw ; StatQuest essaie de vulgariser les statistiques et le machine learning
- https://www.youtube.com/watch?v=trWrEWfhTVg de David Louapre, sur le deep learning
- Tour d'horizon des modèles et algorithmes en 2 vidéos, avec des descriptions rapides de chaque modèle et algorithme ; Machine Learnia, Guillaume Saint-Cirgue : https://www.youtube.com/watch?v=mT6NnslbNLM

128

Vidéos pour réseaux de neurones

- https://www.youtube.com/watch?v=7ell8KEbhJo, en français ; à voir pour commencer ; David Louapre
- https://www.youtube.com/watch?v=XUFLq6dKQok (Machine learnia), en français, une série pour étudier les algorithmes et mathématiques utilisés par IA ; le début présente le machine learning, puis le deep learning

129

- Présentation IA par AWS : https://aws.amazon.com/fr/ai/, en particulier sur overfitting : https://aws.amazon.com/fr/what-is/overfitting/
- Cours coursera sur deep learning : https://www.coursera.org/specializations/deep-learning (accès gratuit pendant 7 jours seulement)
- Hugging Face, site Web pour ceux qui travaille avec le deep learning : https://huggingface.co/

130

- https://www.youtube.com/watch?v=rn1EEd6M7fA : courte vidéo qui explique rapidement le deep learning et qui utilise TensorFlow (librairie qui permet de réaliser le réseau de neurones) et Keras (librairie pour faire du deep learning en entrainant l'IA) ; fait partie de la série « Informatique sans complexe » qui contient d'autres vidéos courtes sur l'IA et sur divers autres domaines de l'informatique : https://www.youtube.com/@InformatiqueSansComplexe

131

- Site Web Kaggle pour une communauté d'utilisateur de IA et de ML (Machine Learning). Pour apprendre (cours, guides), pour les développeurs, pour les chercheurs, et des projets sous la forme de compétitions ou autres formes. https://www.kaggle.com/
- Article de vulgarisation très intéressant sur le phénomène de « grokking » (« au-delà du surapprentissage ») : https://scienceetonnante.substack.com/p/grokking-les-modeles-dia-sont-ils

132

Transformeurs (1/2)

- Cours Hugging Face : https://huggingface.co/learn/nlp-course/chapter1/1
- Visual Guide to Transformer Neural Networks : https://www.youtube.com/playlist?list=PL86uXYUJ7999zE8u2-97i4KG_2Zpufkfb
- Le transformer illustré : https://a-coles.github.io/2020/11/15/transformer-illustre.html (en français), https://jalammar.github.io/illustrated-transformer/, en vidéo : https://www.youtube.com/watch?v=-QH8fRhqFHM
- https://lbourdois.github.io/blog/nlp/Transformer/

Transformeurs (2/2)

- Article fondateur des transformeurs « Attention is all you need », https://arxiv.org/abs/1706.03762
- Article « The annotated transformer » qui illustre l'article avec du code en Python : https://nlp.seas.harvard.edu/2018/04/03/attention.html
- Vidéo sur transformers, par Batool Haider : https://www.youtube.com/playlist?list=PL86uXYUJ7999zE8u2-97i4KG_2Zpufkfb
- Article de Anthropic (LLM « Claude ») sur la « pensée » des LLMs : https://www.anthropic.com/news/tracing-thoughts-language-model